

SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

SEMINAR

Evolucijska optimizacija kompresije transformerskih modela

Tonka Šegvić

Mentor: Domagoj Jakobović

Zagreb, svibanj 2026.

Sadržaj

1. Uvod
2. Pregled postojećih pristupa kompresiji modela
3. GeLaCo
4. Implementacija i rezultati
5. Zaključak i budući rad
6. Literatura

Sažetak

1. Uvod

Brzi rast velikih jezičnih modela posljednjih je godina donio znatan napredak u kvaliteti generiranog teksta, no uz veliki rast računske i memorijske cijene. Kako bi se omogućila uporaba na resursno ograničenim uređajima i smanjio trošak inferencije, razvijene su brojne tehnike kompresije. Istraživanja su pokazala da transformerske arhitekture sadrže znatnu redundanciju, osobito u srednjim slojevima modela s velikim brojem slojeva, što omogućuje uklanjanje cijelih slojeva uz neznatan pad performansi.

U ovom sam radu replicirala metodu GeLaCo na modelu Llama-2-7B.

Detaljna implementacija, skripte i kompletan postupak reprodukcije dostupni su na repozitoriju na GitHubu (github: <https://github.com/Tonka12345/re-GeLaCo.git>), gdje se nalazi i detaljan opis algoritma, odstupanja od eksperimenata autora članka, opširni tehnički izvještaj, rezultati te upute za pokretanje na supek klasteru.

Ovaj dokument je napisan sažeto i možda malo nepotpuno na prvi pogled, ali to je zato što je na README-ju na githubu većina toga već napisana puno detaljnije pa nema smisla stvarati redundanciju.

2. Pregled postojećih pristupa kompresiji modela

Postojeći pristupi kompresiji velikih LLM-ova razvili su se kao odgovor na eksponencijalni rast broja parametara i velike memorijske zahtjeve tijekom inferencije.

Metode kompresije mogu se podijeliti u nekoliko glavnih metoda:

- **kvantizacija** - smanjenje numeričke preciznosti težina
- **destilacija znanja** - treniranje manjeg modela učenika na izlazima većega;
- **orezivanje (pruning)** - uklanjanje pojedinih težina ili cijelih strukturnih grupa;
 - Strukturirano
 - uklanja cijele fizičke komponente, poput glava pažnje ili čitavih transformatorskih blokova
 - ubrzanje na standardnim GPU
 - Nestrukturirano
 - uklanja pojedinačne parametre
 - ne donosi stvarno ubrzanje na standardnim GPU bez specijalizirane hardverske podrške

U kontekstu strukturiranog pruninga, istraživanja pokazuju iznenađujuću redundanciju dubljih slojeva u LLMovima. Metoda ShortGPT (Men i sur., 2024) demonstrirala je da mnogi središnji i dublji slojevi jezičnih modela konvergiraju prema identitetnim transformacijama, odnosno, prosljeđuju podatke bez značajnog mijenjanja skrivenih stanja. Zbog toga je moguće u potpunosti ukloniti neke čitave slojeve bez značajnog gubitka performanse. Ipak, obično brisanje slojeva može uzrokovati nagli gubitak informacija pa kao potencijalno rješenje tog problema metoda LaCo (Yang i sur., 2024) uvodi mehanizam diferencijalnog spajanja težina: umjesto uklanjanja, slojevi se spajaju u jedan kroz diferencijalnu agregaciju, što se može interpretirati kao agregacija znanja. Metoda GeLaCo (Ponce i sur., 2025) nadograđuje LaCo-ovu ideju diferencijalnog spajanja dodajući evolucijsku pretragu prostora mogućih kombinacija skupljanja slojeva, umjesto oslanjanja na pohlepan kriterij sličnosti.

3. GeLaCo

Iako LaCo nudi elegantno matematičko rješenje za spajanje slojeva, odabir optimalne kombinacije slojeva za spajanje predstavlja problem. Budući da su odluke o spajanju diskretne (spajamo ili ne), metode temeljene na gradijentima ovdje nisu primjenjive. Metoda GeLaCo nadograđuje LaCo-ovu ideju diferencijalnog spajanja dodajući evolucijsku pretragu prostora mogućih kombinacija

U višekriterijskoj optimizaciji se istovremeno maksimiziraju dva cilja:

- **omjer kompresije** - udio uklonjenih slojeva u odnosu na izvorni model;
- **modulna sličnost** (module-wise similarity) - prosjek kosinusnih sličnosti triju internih komponenti između originalnog i komprimiranog modela na manjem setu kalibracijskih podataka:
 - Sličnost modula pažnje (Attention Similarity)
 - Sličnost Feed-Forward mreža (FFN Similarity)
 - Sličnost skrivenih stanja (Hidden State Similarity)

Ideja uvođenja modulne sličnosti je da se postigne da komprimirani model interno razmišlja na isti način kao originalni LLM. Autori navode kako modulna sličnost u ovom kontekstu nadmašuje metrike poput KL divergencije ili perpleksnosti.

Svaka jedinka populacije kodirana je genotipom od 3L cijelih brojeva (L označava broj slojeva izvornog modela), grupiranim u L tripleta (b, e, a). Svaki triplet predstavlja kandidatsku operaciju spajanja slojeva [b..e] u jedan sloj, pri čemu aktivacijski bit a određuje primjenjuje li se operacija. Budući da se operacije primjenjuju sekvencijalno na model koji se postupno smanjuje, koristi se preslikavanje ψ koje izvorne indekse slojeva prevodi u trenutne komprimirane indekse i ažurira se nakon svakog uspješnog spajanja.

Spajanje slojeva izvodi se LaCo-ovim diferencijalnim pravilom:

$$\theta^*_b = \theta_b + \sum_k (\theta_{\{b+k\}} - \theta_b)$$

Skupljeni slojevi potom se uklanjaju iz modela.

Algoritam pretrage je NSGA-II s populacijom od 200 jedinki i terminacijom nakon 30 000 evaluacija. Rezultat pretrage je Pareto fronta komprimiranih modela s različitim kompromisima između kompresije i očuvane kvalitete.

Detaljnije: <https://github.com/Tonka12345/re-GeLaCo#1-algorithm-overview>

4. Implementacija i rezultati

Implementacija je podijeljena u dva procesa koja komuniciraju preko dvaju FIFO kanala:


- C++ NSGA-II driver (uporabom biblioteke ECF) — provodi algoritam i zove python evaluator za izračun fitnessa;
- Python evaluator — učitava Llama-2-7B jednom u radnu memoriju GPU-a i obrađuje zahtjeve za izračun fitnessa.

Detalji: <https://github.com/Tonka12345/re-GeLaCo#2-architecture>


Reprodukcija je provedena na HPC klasteru Supek (NVIDIA A100, 40 GB). Pripremljene su dvije varijante pokretanja: skraćena s 4 000 evaluacija te puna s 30 000 evaluacija.

Detalji o hiperparametrima, korištenim operatorima i sl. dostupni su na: <https://github.com/Tonka12345/re-GeLaCo/blob/main/README.md#42-ecf-side-ecfparameterstxt>

Slika 1 prikazuje dobivene pareto fronte nakon 4000 i nakon 30000 evaluacija, a Slika 2 je preuzeta iz originalnog članka i prikazuje rezultate iz koji su autori dobili za isti model.



Slika 1: Pareto fronte nakon 4000 i nakon 30000 evaluacija



Slika 2: Rezultati iz originalnog članka za isti model

Puna pretraga je dovršena nakon 30 000 evaluacija (150 generacija s populacijom od 200 jedinki) u približno 25,7 sati realnog vremena, dok je skraćena varijanta s 4 000 evaluacija završila za otprilike 5 sati. Tijekom pune pretrage keširanje fitnessa po efektivnom skupu operacija nakon ψ preslikavanja postiglo je oko 30 % pogodaka, čime je broj stvarnih izvođenja Llama-2-7B inferencije znatno smanjen.

Konačna pareto fronta pune pretrage sadrži 26 ne-dominiranih jedinki i pokriva cijeli raspon kompresije od 0 % do 93,75 %, dok skraćena varijanta sadrži samo 14 jedinki i ne dohvaća područje niske kompresije. Najviša modulna sličnost koju je puna pretraga pronašla pri 12,5 % kompresije iznosi približno 0,85, dok skraćena varijanta na istoj točki postiže samo 0,49. Puna pretraga je također pronašla i identitet (sličnost 1,0 pri kompresiji 0 %), što potvrđuje da algoritam dolazi do globalno trivijalno optimalnog rješenja u krajnjoj točki fronte.

Usporedba s rezultatima iz originalnog članka (Slika 2) pokazuje da je dobivena fronta malo lošija od originalne. Potencijalni razlozi toga su manja odstupanja od postvaka opisanih u članku (<https://github.com/Tonka12345/re-GeLaCo/blob/main/README.md#9-deviations-from-the-paper>).

Također, neki implementacijski detalji nisu dovoljno specifično opisani, a nisam uspjela pronaći izvorni kod koji su autori koristili za eksperimente tako da je moguće da ima još odstupanja koja su doprijela (malo) različitim rezultatima.

5. Zaključak i budući rad

GeLaCo predstavlja zanimljivu kombinaciju dvaju pristupa — LaCo-ovog diferencijalnog spajanja slojeva i NSGA-II višekriterijske evolucijske pretrage. Rezultat takvog pristupa je Pareto fronta komprimiranih modela koja omogućuje izbor odgovarajućeg kompromisa između stupnja kompresije i očuvanja kvalitete, ovisno o zahtjevima primjene.

Za budući rad bi bilo zgodno isprobati razdvajanje genotipa na odvojene komponente za indekse slojeva i aktivacijske bitove jer bi to povećalo ekspresivnost reprezentacije i potencijalno poboljšalo algoritam. To je bila ideja koju sam razmatrala napraviti, ali sam ipak odlučila da je za početak bolje napraviti jednostavniji pristup.

Prirodan sljedeći korak bila bi i evaluacija pronađenih komprimiranih modela na downstream zadacima (engl. downstream tasks), popraćena kratkim LoRA posttreniravanjem koje, prema autorima članka, vraća velik dio izgubljene kvalitete. Time bi se apstraktna metrika modulne sličnosti pretvorila u konkretne brojke točnosti na stvarnim zadacima i omogućila kvalitetnija usporedba s drugim metodama kompresije.

Također, bilo bi zanimljivo isprobati metodu na drugim modelima (trenutna implementacija je lako prilagodljiva tome), posebice na većim modelima s više slojeva jer je u njima redundancija izraženija. Međutim, u tom slučaju postoje veći hardverski limiti.

6. Literatura

- [1] Ponce, D., Etchegoyhen, T., Del Ser, J. GeLaCo: An Evolutionary Approach to Layer Compression. arXiv:2507.10059, 2025.
- [2] Yang, Y., Cao, Z., Zhao, H. LaCo: Large Language Model Pruning via Layer Collapse, 2024.
- [3] Gromov, A., Tirumala, K., Shapourian, H., Glorioso, P., Roberts, D. A. The Unreasonable Ineffectiveness of the Deeper Layers, 2024.
- [4] Men, X., Xu, M., Zhang, Q., Wang, B., Lin, H., Lu, Y., Han, X., Chen, W. ShortGPT: Layers in Large Language Models are More Redundant Than You Expect, 2024.
- [5] Ma, X., Fang, G., Wang, X. LLM-Pruner: On the Structural Pruning of Large Language Models, 2023.

Sažetak

U radu se istražuje redundancija u transformerskim modelima i postojeći pristupi njihovoj kompresiji. Glavni dio rada čini analiza evolucijskog pristupa predloženog u radu GeLaCo: An Evolutionary Approach to Layer Compression (Ponce, Etchegoyhen i Del Ser, 2025). U eksperimentalnom je dijelu provedena djelomična reprodukcija rezultata na modelu Llama-2-7B te analiza dobivenih rješenja s rezultirajuće Pareto fronte.

Ključne riječi:

GeLaCo; veliki jezični modeli; kompresija LLM-ova; spajanje slojeva; skupljanje slojeva; rezanje; evolucijski algoritmi; višeciljna optimizacija; NSGA; transformeri.